Instituicao de Ensino Demo

Curso: Engenharia de Software

6o Semestre

Material de Estudo

Machine Learning

---

1. INTRODUCAO

Machine Learning e a area da IA que permite que computadores aprendam a partir de dados sem serem explicitamente programados. Em vez de regras fixas, algoritmos de ML identificam padroes nos dados e fazem previsoes. Aplicacoes incluem recomendacao de conteudo (Netflix, Spotify), deteccao de fraudes, diagnostico medico, traducao automatica e muito mais. Para engenheiros de software, ML e uma habilidade cada vez mais demandada pelo mercado.

Ementa: Fundamentos de aprendizado de maquina. Aprendizado supervisionado: regressao e classificacao. Aprendizado nao-supervisionado: clustering e reducao de dimensionalidade. Avaliacao de modelos. Feature engineering. Redes neurais e deep learning. Aplicacoes praticas.

2. CONCEITOS FUNDAMENTAIS

A seguir, apresentamos os conceitos-chave desta disciplina com explicacoes didaticas e exemplos praticos para facilitar o aprendizado.

2.1 Aprendizado Supervisionado

No aprendizado supervisionado, o modelo aprende a partir de dados rotulados (entrada + saida esperada). Regressao preve valores continuos (preco de imovel). Classificacao preve categorias (spam ou nao-spam). Algoritmos populares: Regressao Linear, Regressao Logistica, Arvores de Decisao, Random Forest, SVM e KNN. O modelo e treinado em dados de treino e avaliado em dados de teste.

Exemplo:

```
Regressao Linear - prever preco de imovel:
preco = w1*area + w2*quartos + w3*localizacao + b

Em Python com scikit-learn:
from sklearn.linear_model import LinearRegression
modelo = LinearRegression()
modelo.fit(X_treino, y_treino)
previsao = modelo.predict(X_teste)

Classificacao - spam ou nao-spam:
from sklearn.ensemble import RandomForestClassifier
clf = RandomForestClassifier()
clf.fit(X_treino, y_treino)
resultado = clf.predict(novo_email)
```

2.2 Avaliacao de Modelos e Overfitting

Avaliar modelos corretamente e crucial. Metricas de regressao: MAE, MSE, R2. Metricas de classificacao: acuracia, precisao, recall, F1-score, AUC-ROC. Overfitting ocorre quando o modelo memoriza os dados de treino mas nao generaliza. Solucoes: validacao cruzada, regularizacao (L1/L2), mais dados, early stopping.

Exemplo:

```
Validacao cruzada (5-fold):
Dados divididos em 5 partes iguais
Rodada 1: treina em 2,3,4,5 - testa em 1
Rodada 2: treina em 1,3,4,5 - testa em 2
...
Rodada 5: treina em 1,2,3,4 - testa em 5
```

```
Resultado: media das 5 avaliacoes
```

```
from sklearn.model_selection import cross_val_score
scores = cross_val_score(modelo, X, y, cv=5)
print(f"Acuracia media: {scores.mean():.2f}")
```

3. RESUMO DOS PRINCIPAIS TOPICOS

O conteudo programatico da disciplina esta organizado nas seguintes unidades:

- Unidade 1: Fundamentos de ML - tipos de aprendizado, pipeline de dados
- Unidade 2: Regressao linear e logistica
- Unidade 3: Arvores de decisao, Random Forest e Gradient Boosting
- Unidade 4: SVM, KNN e Naive Bayes
- Unidade 5: Clustering - K-Means, DBSCAN, hierarquico
- Unidade 6: Avaliacao de modelos - metricas, validacao cruzada, overfitting
- Unidade 7: Feature engineering e selecao de features
- Unidade 8: Introducao a deep learning - redes neurais com TensorFlow/PyTorch

Cada unidade aborda um aspecto fundamental da disciplina, construindo progressivamente o conhecimento necessario para dominar o tema. Recomenda-se estudar as unidades na ordem apresentada.

4. EXERCICIOS DE FIXACAO

Resolva os exercicios abaixo para verificar seu entendimento dos conceitos apresentados.

Questao 1 (Multipla Escolha)

Qual tipo de aprendizado usa dados rotulados para treinar o modelo?

a) Nao-supervisionado
b) Supervisionado
c) Por reforco
d) Semi-supervisionado

Questao 2 (Dissertativa)

Explique o que e overfitting e cite 3 tecnicas para evita-lo.

Questao 3 (Multipla Escolha)

Qual algoritmo e mais adequado para agrupar dados sem rotulos?

a) Regressao Linear
b) Random Forest
c) K-Means
d) Regressao Logistica

Questao 4 (Dissertativa)

Descreva o pipeline completo de um projeto de Machine Learning, desde a coleta de dados ate o deploy do modelo.

5. DICAS DE ESTUDO E RECURSOS ADICIONAIS

Para maximizar seu aprendizado nesta disciplina, siga estas recomendacoes:

• Comece com scikit-learn antes de ir para TensorFlow ou PyTorch.
• Pratique com datasets do Kaggle — participe de competicoes.
• Entenda a matematica por tras dos algoritmos (algebra linear, estatistica).
• Leia o livro "Maos a Obra" de Aurelien Geron — e o melhor guia pratico.
• Construa projetos end-to-end: coleta, limpeza, treino, avaliacao, deploy.

Bibliografia Recomendada:

• GERON, A. Maos a Obra: Aprendizado de Maquina com Scikit-Learn, Keras e TensorFlow. Alta Books, 2021.
• FACELI, K. et al. Inteligencia Artificial: Uma Abordagem de Aprendizado de Maquina. LTC, 2021.
• BISHOP, C. Pattern Recognition and Machine Learning. Springer, 2006.

6. GLOSSARIO DE TERMOS IMPORTANTES

Consulte este glossario sempre que encontrar um termo desconhecido durante seus estudos.

- **Aprendizado supervisionado**: treino com dados rotulados (entrada + saida).
- **Aprendizado nao-supervisionado**: treino sem rotulos (encontra padroes).
- **Overfitting**: modelo memoriza treino mas nao generaliza para novos dados.
- **Feature**: variavel de entrada usada pelo modelo para fazer previsoes.
- **Validacao cruzada**: tecnica para avaliar modelos dividindo dados em folds.
- **Acuracia**: proporcao de previsoes corretas sobre o total.
- **F1-score**: media harmonica entre precisao e recall.
- **Clustering**: agrupamento de dados similares sem rotulos.