Instituicao de Ensino Demo

Curso: Engenharia de Software

7o Semestre

Material de Estudo

Big Data

---

1. INTRODUCAO

Big Data refere-se ao processamento e analise de conjuntos de dados massivos que excedem a capacidade de ferramentas tradicionais. Com a explosao de dados gerados por redes sociais, IoT, transacoes financeiras e sensores, a capacidade de processar e extrair valor desses dados e uma competencia critica. Tecnologias como Hadoop, Spark e Kafka permitem processar petabytes de dados de forma distribuida e eficiente.

Ementa: Fundamentos de Big Data. Os 5 Vs (Volume, Velocidade, Variedade, Veracidade, Valor). Ecossistema Hadoop. Apache Spark. Data lakes e data warehouses. ETL e pipelines de dados. Processamento em tempo real. Visualizacao de dados.

2. CONCEITOS FUNDAMENTAIS

A seguir, apresentamos os conceitos-chave desta disciplina com explicacoes didaticas e exemplos praticos para facilitar o aprendizado.

2.1 Apache Spark e Processamento Distribuido

Apache Spark e o framework mais popular para processamento de Big Data. Diferente do MapReduce (Hadoop), Spark processa dados em memoria, sendo ate 100x mais rapido. Suporta batch e streaming. DataFrames oferecem API similar a SQL. Spark SQL permite consultas SQL em dados distribuidos. MLlib fornece algoritmos de machine learning escalaveis.

Exemplo:

```
PySpark - processando dados de vendas:
from pyspark.sql import SparkSession

spark = SparkSession.builder.appName("vendas").getOrCreate()
df = spark.read.csv("vendas.csv", header=True)

# Total de vendas por regiao
df.groupBy("regiao").sum("valor").show()

# SQL
df.createOrReplaceTempView("vendas")
spark.sql("SELECT regiao, SUM(valor) FROM vendas GROUP BY regiao").show()
```

2.2 Data Lakes e Pipelines de Dados

Um data lake armazena dados brutos em qualquer formato (estruturado, semi-estruturado, nao-estruturado). Diferente do data warehouse, que armazena dados ja processados e estruturados. Pipelines de dados (ETL) extraem dados de fontes, transformam e carregam no destino. Ferramentas como Apache Airflow orquestram pipelines complexos com dependencias e agendamento.

Exemplo:

```
Pipeline ETL com Airflow:
1. Extract: ler dados de API, banco, arquivos
2. Transform: limpar, validar, agregar
3. Load: salvar no data warehouse

Data Lake (S3):
s3://meu-data-lake/
raw/ -> dados brutos (JSON, CSV, logs)
```

```
processed/ -> dados limpos e transformados
```

```
curated/ -> dados prontos para analise
```

3. RESUMO DOS PRINCIPAIS TOPICOS

O conteudo programatico da disciplina esta organizado nas seguintes unidades:

- Unidade 1: Fundamentos de Big Data - os 5 Vs e desafios
- Unidade 2: Ecossistema Hadoop - HDFS, MapReduce, YARN
- Unidade 3: Apache Spark - RDDs, DataFrames, Spark SQL
- Unidade 4: Data lakes vs data warehouses
- Unidade 5: ETL e pipelines de dados - Airflow, Glue
- Unidade 6: Processamento em tempo real - Kafka, Spark Streaming, Kinesis
- Unidade 7: Bancos NoSQL para Big Data - Cassandra, MongoDB, DynamoDB
- Unidade 8: Visualizacao de dados - dashboards, storytelling com dados

Cada unidade aborda um aspecto fundamental da disciplina, construindo progressivamente o conhecimento necessario para dominar o tema. Recomenda-se estudar as unidades na ordem apresentada.

4. EXERCICIOS DE FIXACAO

Resolva os exercicios abaixo para verificar seu entendimento dos conceitos apresentados.

Questao 1 (Multipla Escolha)

Quais sao os 5 Vs do Big Data?

a) Volume, Velocidade, Variedade, Veracidade, Valor
b) Volume, Velocidade, Visao, Verificacao, Valor
c) Volume, Versatilidade, Variedade, Veracidade, Velocidade
d) Volume, Velocidade, Variedade, Virtualizacao, Valor

Questao 2 (Dissertativa)

Compare data lake e data warehouse: quando usar cada um?

Questao 3 (Multipla Escolha)

Qual framework processa Big Data em memoria, sendo mais rapido que MapReduce?

a) Hadoop
b) Hive
c) Spark
d) Pig

Questao 4 (Dissertativa)

Projete um pipeline de dados para processar logs de acesso de um site com milhoes de visitas diarias.

5. DICAS DE ESTUDO E RECURSOS ADICIONAIS

Para maximizar seu aprendizado nesta disciplina, siga estas recomendacoes:

• Instale PySpark localmente e pratique com datasets do Kaggle.
• Estude o livro "Designing Data-Intensive Applications" de Martin Kleppmann.
• Explore servicos de Big Data na AWS: EMR, Glue, Athena, Kinesis.
• Pratique SQL avancado — e a base para trabalhar com dados.
• Aprenda a criar dashboards com ferramentas como Metabase ou Superset.

Bibliografia Recomendada:

• WHITE, T. Hadoop: The Definitive Guide. O'Reilly, 2015.
• CHAMBERS, B.; ZAHARIA, M. Spark: The Definitive Guide. O'Reilly, 2018.
• KLEPPMANN, M. Designing Data-Intensive Applications. O'Reilly, 2017.

6. GLOSSARIO DE TERMOS IMPORTANTES

Consulte este glossario sempre que encontrar um termo desconhecido durante seus estudos.

- **Big Data**: dados massivos que excedem capacidade de ferramentas tradicionais.
- **Hadoop**: framework open source para processamento distribuido.
- **Spark**: framework rapido para processamento de Big Data em memoria.
- **Data Lake**: repositorio de dados brutos em qualquer formato.
- **Data Warehouse**: repositorio de dados estruturados e processados.
- **ETL**: Extract, Transform, Load — pipeline de processamento de dados.
- **Kafka**: plataforma de streaming de eventos distribuida.
- **MapReduce**: modelo de programacao para processamento paralelo.